

## 一种基于免疫选择的粒子群优化算法\*

魏建香<sup>1,2\*\*</sup>, 孙越泓<sup>3</sup>, 苏新宁<sup>1</sup>

(1. 南京大学信息管理系, 南京, 210093; 2. 南京人口管理干部学院信息科学系, 南京, 210042;  
3. 南京师范大学数学与计算机学院, 南京, 210097)

**摘要:** 粒子群算法是一种新的群体智能算法, 被广泛用于各种复杂优化问题的求解, 但算法存在着过早收敛问题. 为了克服算法早熟的缺点, 将粒子群看作是一个复杂的免疫系统, 借鉴生物学中免疫系统自我调节的机制, 提出了一种新的基于免疫选择的粒子群优化算法(IS-PSO). 免疫系统中的抗原、抗体和亲和度分别对应了待优化函数的最优解、候选解和适应度. IS-PSO 通过免疫算法中免疫记忆、疫苗接种、免疫选择等操作有效地调节 PSO 算法中种群的多样性. 给出了算法的详细步骤, 并将本文提出的算法与基本的粒子群算法(bPSO)在几个典型 Benchmark 函数的优化问题应用中进行比较, 仿真结果表明: IS-PSO 算法可以有效避免早熟问题, 提高粒子群算法求解复杂函数的全局优化性能.

**关键词:** 粒子群优化, 种群多样性, 免疫选择, 早熟

**中图分类号:** TP 18

## A novel particle swarm optimization based on immune selection

Wei Jian-Xiang<sup>1,2</sup>, Sun Yue-Hong<sup>3</sup>, Su Xin-Ning<sup>1</sup>

(1. Department of Information Management, Nanjing University, Nanjing, 210096, China; 2. Department of Information Science, Nanjing College for Population Programme Management, Nanjing, 210042, China; 3. School of Mathematics and Computer Science, Nanjing Normal University, Nanjing, 210097, China)

**Abstract:** Particle swarm optimization (PSO), a novel swarm intelligence algorithm, is proved to be a valid optimization technique and has been applied in many areas successfully. However, like other evolutionary algorithms, PSO also suffered from the premature convergence problem, especially for the large scale and complex problems. In order to overcome the shortcoming, this paper regards the swarm as a complex immune system, uses for reference from the self-adjustment mechanism of immune system, and proposes a novel PSO based on immune selection called IS-PSO (immune selection particle swarm optimization). Antigen, antibody, and affinity between antigen and antibody are corresponding to the best solution, the candidate solution, and the fitness values of the solution on the objective function, respectively. IS-PSO adjusts swarm diversity via immune memory, inoculate vaccine and immune selection and so on. The steps of the algorithm are given in detail. The proposed algorithm is

\* 基金项目: 国家社科基金青年自选项目(09CTQ022), 江苏省“六大人才高峰”项目(09-E-016)

收稿日期: 2009-05-30

\*\* 通讯联系人, E-mail: jxwei@foxmail.com

applied to some classical Benchmark functions optimization and compared with the basic PSO(bPSO). Simulation results show IS-PSO can maintain better swarm diversity, avoid the premature convergence effectively and improve the global performance of PSO in solving the complex functions optimization.

**Key words:** particle swarm optimization, swarm diversity, immune selection, premature

粒子群优化算法(PSO)作为一种新的基于迭代的最优化方法,是由 Kennedy 和 Eberhart 于 1995 年提出的<sup>[1]</sup>.最初的想法是模拟鸟类或鱼类觅食的过程来寻求最优解,它一经提出,就受到了业界的广泛关注,在函数优化、模式分类、模糊控制等领域取得了很大的成功<sup>[2~8]</sup>. PSO 有着深刻的群体智能背景,具有收敛速度快、通过粒子的自我认知和社会认知进行信息共享、采用实数编码使得算法可以直接在问题域上进行处理,无需转换,算法简单,易于实现等优点,但其缺陷也是明显的:还没有给出数学意义上的严格的收敛性证明;各种参数值的确定主要通过经验值来确定;不能持续地保持种群多样性,导致算法容易“早熟”,信息共享机制简单.近几年,许多学者对 PSO 算法进行了改进,如 Peram 等<sup>[9]</sup>提出了基于适应度、距离与比例的 FDR-PSO(fitness-distance-ratio based PSO); Parsopoulos and Vrahatis<sup>[10]</sup>将全局 PSO 和局部 PSO 两个版本整合,提出 UPSO(unified PSO);Liang 等<sup>[11]</sup>提出了一种基于学习策略的 CLPSO(comprehensive learning PSO);倪梁方等<sup>[12]</sup>提出了一种基于均方误差准则的集粒子云算法 EPSA(ensemble particle swarm algorithm); Al-Kazemi and Mohan<sup>[13]</sup>提出一种多阶段微粒群算法(MPSO, multi-phase particle swarm optimization).这此算法都从各个层面对算法进行了改进,取得了较好的效果,但不能从根本上解决早熟问题.众所周知,在各种群体智能的优化算法中,产生早熟的重要原因这是由于算法在运行到一定阶段后,个体间的差异变小,算法不能跳出局部而过早地收敛,因此种群多样性是影响算法收敛性能的重要因素.为了保证 PSO 算法在演化过程中种

群的多样性,Lovbjerg 等人<sup>[14]</sup>将遗传算法中的子群体及繁殖的概念引入微粒群算法中;Li<sup>[15]</sup>提出了基于物种的邻域自适应选择方案来保证群体多样性;Riget 等<sup>[16]</sup>则通过“吸引”和“扩散”算子控制群体多样性;Xie 等<sup>[17]</sup>用一个新的粒子替换不活泼的粒子来实现群体中个体层次下的再组织,来保持群体的多样性;介婧等<sup>[18]</sup>提出了基于群体多样性反馈控制的自组织微粒群算法 SOPSO(self-organized PSO).上述算法不同程度地提高了粒子群算法的寻优精度,但有些改进后的算法的计算复杂度大大提高;有些算法是基于简单的人为控制,缺乏理论依据,不具有普遍性和通用性,鲁棒性差.

受生物学中免疫系统能保证抗体多样性的思想的启示,本文提出了一种基于免疫选择的 PSO 算法 IS-PSO(immune selection PSO).IS-PSO 借鉴免疫系统的自适应识别和排除侵入机体的抗原异物的功能,将生物免疫系统的记忆、多样性、特征提取、识别与选择等机制引入粒子群算法,通过免疫操作,使粒子在演化的进程中持续地保持了个体的差异性,提高了算法的收敛性能,有效地避免了算法陷于局部最优.

## 1 人工免疫与粒子群算法概述

**1.1 人工免疫算法** 生物免疫系统的基本功能是区分自我和非我,免疫识别是生物免疫系统各种功能的基础.根据 Burnet 的细胞克隆选择学说,生物免疫系统能够识别和抵抗各种抗原的袭击,是因为在胚胎期由于免疫细胞在增殖中发生基因突变,形成了免疫细胞的多样性<sup>[19]</sup>.免疫系统具有模式识别、学习与记忆、多样性的产生、噪声耐受、归纳概括、分布检测及优化等多种功能.人工免疫算法是在模拟生物

免疫系统的基础上提出的,通过对生物免疫系统的抽象、概括、加工和归纳,形成了克隆、变异与免疫选择等一系列步骤.目前,人工免疫已经成为人工智能研究的一个热点,在函数优化<sup>[20~21]</sup>、旅行商问题<sup>[22]</sup>、人工神经网络设计<sup>[23]</sup>、电网规划<sup>[24]</sup>等领域获得了成功的应用.由于免疫系统本身是一个非常庞大和复杂的系统,因而上述提出的人工免疫算法相对比较复杂.为避免计算的复杂性,本文选择了人工免疫算法中几个重要的免疫操作,摒弃了较复杂的交叉变异过程,保持了 PSO 本身的简易性,采用实数编码,无需编码转换,使得算法容易实现并且可以在问题域上直接求解.

**1.2 基本粒子群(basic particle swarm optimization, bPSO)** 在 bPSO 算法求解最优化问题时,通常将所求问题的解设计为搜索空间中一个粒子,每个粒子由三部分组成:当前位置  $x$ 、飞行速度  $v$  和粒子的适应度  $fitness$  组成,表示为  $P(x, v, fitness)$ . 在迭代的过程中,粒子通过更新两个“极值”来更新自己:一个是粒子本身所找到的最优解,称之为粒子的自身认知能力,记为  $P_{best}$ ;另一个是整个粒子群目前所找到的最优解,称之为粒子的社会认知能力,记为  $G_{best}$ . 在找到两个最优解以后,每一个粒子通过以下公式更新自己的速度和位置:

$$v_i^{(t+1)} = \omega v_i^{(t)} + c_1 r_1 (P_{best_i}^{(t)} - x_i^{(t)}) + c_2 r_2 (G_{best}^{(t)} - x_i^{(t)}) \quad (1)$$

$$x_i^{(t+1)} = x_i^{(t)} + v_i^{(t+1)} \quad (2)$$

其中  $P_{best_i}^{(t)}$  为第  $i$  个粒子到第  $t$  代为止搜索到的历史最优解,  $G_{best}^{(t)}$  为整个粒子群到目前为止搜索到的最优解,  $V_i$  是第  $i$  个粒子当前飞行速度,  $c_1$  为自身认知系数,  $c_2$  为社会认知系数,  $r_1$ 、 $r_2$  是  $[0, 1]$  之间的随机数.

## 2 相关定义

**定义 1** 亲和度是用来表示抗体与抗原之间的接近程度,用  $affinity$  表示,定义如下:

$$affinity(x_i) = \frac{1}{f+1} \quad (3)$$

公式中的  $f$  为待优化函数的值. 在求解函

数最小值问题中,满足约束条件的待优化目标函数的最优解视为抗原,函数的候选解  $x_i$  (第  $i$  个粒子) 视为抗体. 当  $f$  越小,亲和度越高,则抗体与抗原越接近.

**定义 2** 疫苗是指待求问题的先验知识,是对最佳个体基因的估计. 在本文中我们采用一种新的疫苗定义方式,即选用多个最佳个体的平均值作为疫苗. 假设现有  $a$  个最好的抗体群为  $X = (x_1, x_2, \dots, x_a)^T \subset R^{n \times k}$ , 则疫苗  $Vaccine$  定义为:

$$vaccine(i) = \frac{1}{a} \sum_{j=1}^a x_j, i = 1, 2, \dots, k \quad (4)$$

公式中疫苗的基因取值为各个优良个体的对应基因的平均值,因此继承了优良个体的优势,具有较强的代表性,为后面的疫苗接种奠定了基础.

**定义 3** 抗体浓度是衡量抗体多样性的重要指标,通常的表示方法是用各个抗体之间的亲和度大小的差异来描述. 本文采用抗体亲和度区间分布频数来定义抗体浓度. 设共有  $n$  个抗体  $x_i, i = 1, 2, \dots, n$ , 其亲和度分别  $affinity_1, affinity_2, \dots, affinity_n$ , 排序后的适应度区间为  $[Minaffinity, Maxaffinity]$ , 将该区间  $m$  等分,则每个等分区间的长度为  $(Maxaffinity - Minaffinity)/m$ , 分别记为  $L_1, L_2, \dots, L_m$ . 求出每一个等分区间中抗体适应度的个数,记为  $Count(j)$ ,  $j$  为区间编号,  $j = 1, 2, \dots, m$ , 将区间的浓度定义为  $Count(j)/m$ . 将每个抗体的浓度  $density$  定义为该抗体适应度所在区间的浓度(用  $D$  表示).

$$density(x_i) = D(L_j) = \frac{Count(j)}{m},$$

$$j = 1, 2, \dots, m, i = 1, 2, \dots, n \quad (5)$$

由定义 3 可以看出同一区间中抗体的浓度是相同的. 从理论上分析,在每一区域内的浓度应该是相同的,这样使得有些浓度虽低但发展趋势较好的抗体获得一定的进化机会. 由于传统的浓度定义在距离的基础上,使得在同一区间中抗体的浓度产生差异,从而在选择过程中会使得有些浓度虽低但发展趋势较好的抗体不

能获得进化的机会。

**定义 4** 在免疫机制中,高浓度低亲和度的抗体要抑制,而低浓度高亲和率的抗体要促进。因此在决定某些抗体能进入直一代的概率  $P_s$  是由两个概率即基于浓度的选择概率  $P_d$  和基于亲和度的选择概率  $P_f$  共同决定的。 $P_d$  和  $P_f$  分别定义为:

$$P_d(x_i) = 1 - \frac{D(x_i)}{\sum_{i=1}^n D(x_i)}, i = 1, 2, \dots, n \quad (6)$$

与

$$P_f(x_i) = \frac{\text{fitness}(x_i)}{\sum_{i=1}^n \text{fitness}(x_i)}, i = 1, 2, \dots, n \quad (7)$$

因此我们将抗体促进与抑制的选择概率  $P_s$  定义为:

$$P_s(x_i) = \alpha P_f(x_i) + (1 - \alpha) P_d(x_i), \\ 0 < \alpha, P_f, P_d < 1 \quad (8)$$

根据  $P_d$  的定义,浓度越高,选择的概率越小;根据  $P_f$  的定义,亲和度越高,选择的概率越大,公式(8)中的  $\alpha$  是用来调节两个概率的平衡系数,通常  $\alpha = 0.7$ 。

**定义 5** 本文采用文献[16]提出的个体到群体中心的平均点距度量各群多样性,计算公式如下:

$$\text{Diversity}(t) = \frac{\sum_{i=1}^n \sqrt{\sum_{j=1}^m (x_{ij}(t) - \bar{x}_j(t))^2}}{n \times |L|} \quad (9)$$

公式中的  $n$  代表群体规模,  $|L|$  代表搜索空间的\*\*最大对角线长度,  $m$  代表搜索空间的维数,  $\bar{x}_j(t)$  代表第  $t$  代时种群的平均中心的第  $j$  维分量。该多样性测度与种群规模及搜索空间的大小无关,能较好地描述个体在解空间中分布的疏密状况。

### 3 算法设计

基于免疫选择的粒子群优化算法 (IS-PSO) 是在标准粒子群算法中引入免疫机

制,以改善种群的多样性,提高算法的收敛精度。具体的思路是将最优解视为抗原,粒子看作是抗体,抗体与抗原之间的接近程度看作亲和度,通过免疫记忆、抗体的促进与抑制、疫苗接种、免疫选择、粒子运动等操作实现优化过程,算法的基本流程如图 1。从理论上分析,IS-PSO 算法具有以下特点:

(1) 保持了基本粒子群算法的学习和信息共享机制;

(2) 抗原识别和免疫记忆加强了粒子间信息共享,一方面模拟生物进化理论,通过“优胜劣汰”保证较优良的个体进入下一代;另一方面通过“重新初始化”的机制保持种群的多样性,提高了算法收敛性能;

(3) 免疫调节通过“高浓度低亲和度的抗体进行抑制,低浓度高亲和度的抗体进行促进”的机制,使算法更好地保持了种群的多样性,减少了算法陷于局部最优的概率;

(4) 接种疫苗和免疫选择使得优秀个体的基因得到继承,提高了算法的寻优能力。

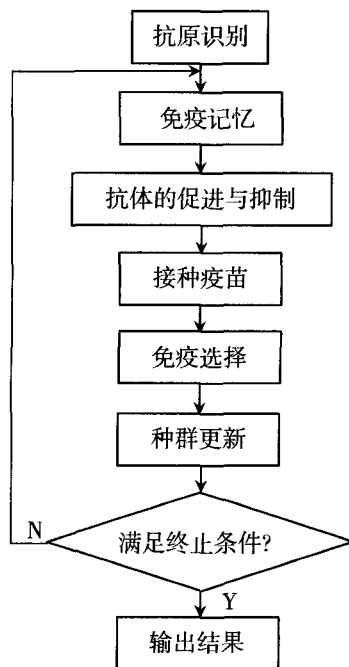


图 1 IS-PSO 算法流程图

Fig. 1 IS-PSO algorithm procedure

算法的具体步骤如下:

**Step 1** 问题定义. 待优化函数的最优解为抗原, 候选解为抗体.

**Step 2** 抗体初始化. 设抗体规模为  $n$ , 空间维度为  $k$ , 抗体采用实数编码. 在自变量范围内随机产生候选解  $X = (x_1, x_2, \dots, x_n)^T \subset R^{n \times k}$  作为初始抗体群, 初始速度  $V = (v_1, v_2, \dots, v_n)^T \subset R^{n \times k}$ , 根据公式(3) 计算所有抗体的亲和度. 根据亲和度, 计算出每个抗体和整个抗体群所经历的历史最好位置, 记为  $P_{\text{best}}$  和  $G_{\text{best}}$ ;

**Step 3** 免疫记忆. 将  $n$  个亲和度 *affinity* 从小到大排序, 取最大的 20% 的亲和度所对应的抗体作为抗体免疫记忆库.

**Step 4** 定义疫苗. 取抗体免疫记忆库中的抗体基因的平均值作为疫苗基因, 见公式(4).

**Step 5** 抗体的促进与抑制. 如果抗原是新的, 则随机产生  $m$  个新抗体; 否则从免疫记忆库中抽取  $m$  个新抗体, 形成  $n + m$  个抗体群, 根据公式(5) ~ (8) 计算选择概率  $P_s$ , 采用轮盘赌注法选择  $n$  个抗体进入下一代. 轮盘赌注法在确保优秀个体进入下一代的同时, 保持了选择的压力和随机性; 采用直接排序选择的方法将减少选择的随机性且个体选择是不重复的. 而在选择的过程中, 重复选择同一个个体是允许的, 因为在新的进化过程中, 它们将产生分化, 从而也能保证个体的多样性.

**Step 6** 疫苗接种. 随机选择疫苗 50% 的基因, 对亲和度较低的部分抗体(约占总体的 20%) 对应的基因进行替换操作.

**Step 7** 免疫选择. 对于经过接种后的抗体, 如果亲和度不如父代, 选择原来的抗体.

**Step 8** 更新位置. 根据公式(2) 来更新粒子位置.

**Step 9** 更新  $P_{\text{best}}$  和  $G_{\text{best}}$ . 重新计算每个抗体的 *affinity*、 $P_{\text{best}}$  和  $G_{\text{best}}$ . 对于每一个抗体, 如果它目前的  $P_{\text{best}}$  比历史所经历的  $P_{\text{best}}$  好, 则更新  $P_{\text{best}}$ ; 对于整个抗体群, 如果目前的  $G_{\text{best}}$  比历史所经历的  $G_{\text{best}}$  好, 则更新  $G_{\text{best}}$ ;

**Step 10** 更新速度. 按照公式(1) 更新粒

子的速度, 速度被限制在  $(-V_{\text{max}}, V_{\text{max}})$  之间; 如果更新后的速度大于  $V_{\text{max}}$ , 则取  $V_{\text{max}}$ , 如果小于  $-V_{\text{max}}$ , 则取  $-V_{\text{max}}$ .

**Step 11** 终止操作. 如果已经达到最大迭代次数或目标函数值收敛, 则算法终止; 否则转 Step 3.

## 4 实验仿真与分析

**4.1 参数设置与 Benchmark 函数的选择** 为了保证算法收敛, 惯性权重  $\omega$  及学习系数  $c_1$ 、 $c_2$  都采用线性变化策略. 惯性权重  $\omega$  一般都在  $[0.1, 0.8]$  之间取值, 文献[25] 通过大量实验证明, 如果  $\omega$  随算法迭代的进行而线性减小, 将显著改善算法的收敛性能, 这是因为当  $\omega$  从大到小变化时, 粒子搜索的范围可以从一个较大的空间逐渐变化到很小的区域, 这正好符合 PSO 的基本思想. 因此  $\omega$  的变化策略可以用公式  $\omega = \omega_{\text{max}} - T * \frac{\omega_{\text{max}} - \omega_{\text{min}}}{T_{\text{max}}}$  ( $T$  为当前代数,  $T_{\text{max}}$  为最大迭代次数) 表示. 对于学习系数  $c_1$ 、 $c_2$  的取值范围为  $[0, 4]$ . 由于粒子在运动的初期, 粒子本身的经验不足因此需要更多地向群体学习, 也就是说  $c_1$  的取值比  $c_2$  要小; 当粒子运动到一定的阶段时, 粒子本身积累了一定的经验后, 自我学习的能力加强, 因此  $c_1$  的取值比  $c_2$  要大. 我们将学习系数的变化策略设置为: 在  $c_1 + c_2 = 4$  时,  $c_1$  线性递增而  $c_2$  线性递减,  $c_2 = c_{\text{max}} - T * \frac{c_{\text{max}} - c_{\text{min}}}{T_{\text{max}}}$ , 种群规模  $n = 100$ .

我们选择了 4 个典型的 Benchmark 函数作为两种算法的测试函数. 表 1 为这些函数的名称、公式、维数、范围和目标最小值. 其中  $f_1 \sim f_2$  都是单峰函数, 可以用来测试算法的寻优精度, 考察算法的执行性能;  $f_3 \sim f_4$  都是多峰函数, 具有广泛的搜索空间、大量的局部极小点和高大的障碍物, 一般算法都较难找到全局最优值, 因此可以用来检验算法跳出局部最优的能力. 两种算法的迭代次数均为 500. 在进行算法仿真时, 我们将 bPSO 和 IS-PSO 在所有参数设置相同的情形下, 对 4 个函数独立运行 50 次后

结果取平均值进行比较.

**4.2 算法性能比较** 从表 2 可以看出, IS-PSO 对所有函数的优化精度均好于 bPSO. IS-PSO 对  $f_1$ :Sphere 函数以概率 1 收敛到 0(Matlab 中,  $E-16$  为 0), 收敛代数大约在 450

代左右, 对其它 3 个函数的优化精度都小于  $E-9$ , 显示了 IS-PSO 具有很强的寻优能力; bPSO 对于多峰函数  $f_3$ :Rastrigin 几乎无能为力(最小值为 45.476 0, 离目标值 0 相去甚远), 对它 3 个函数的优化平均在  $E-3$  左右.

表 1 Benchmark 函数

Table 1 Benchmark functions

函数	公式	维数	范围	目标最小值
$f_1$ :Sphere	$f_1(x) = \sum_{i=1}^n x_i^2$	30	$[-100, 100]^{30}$	0
$f_2$ :Quadric	$f_2(x) = \sum_{i=1}^n \left( \sum_{j=1}^i x_j \right)^2$	30	$[-100, 100]^{30}$	0
$f_3$ :Rastrigin	$f_3(x) = \sum_{i=1}^n (x_i^2 - 10 \cos(2\pi x_i) + 10)$	30	$[-100, 100]^{30}$	0
$f_4$ :Griewank	$f_4(x) = \sum_{i=1}^n \frac{1}{4000} (x_i)^2 - \prod_{i=1}^n \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1$	30	$[-600, 600]^{30}$	0

表 2 两种算法结果比较

Table 2 Result comparison of two algorithms

函数	bPSO				IS-PSO			
	Average	Maximum	Minimum	Standard Deviation	Average	Maximum	Minimum	Standard Deviation
$f_1$	5.62E-03	1.09E-02	1.60E-03	3.09E-03	0	0	0	0
$f_2$	1.74E-03	6.20E-03	1.51E-07	2.27E-03	3.2488E-10	2.9227E-09	0	8.6831E-10
$f_3$	52.1837	66.9904	45.4760	5.5872	1.1842E-15	1.07E-14	0	3.3495E-15
$f_4$	1.21E-02	4.91E-02	2.16E-08	1.37E-02	9.52E-10	6.34E-09	0	1.9966E-09

图 2 和 3 分别显示了两种算法对单峰函数和多峰函数优化性能的比较. 从总体上看, bPSO 过早收敛, 优化精度不高, 特别是对于多峰函数优化问题则更差; 而 IS-PSO 相对而言收敛要慢, 但是优化精度相当高.

**4.3 种群多样性仿真分析** PSO 算法本身的特点是在粒子运动的前期必须在一个较大范围内进行搜索, 而在后期则需要在一个狭小的范围内进行开采. 种群的多样性是一把“双刃剑”, 一方面较低的多样性是陷于早熟的原因, 但另一方面较低的多样性也能增加算法在一个局部的区域找到更好解的机会. 因此, 既要维持较低的种群多样性水平, 但又不能保持多样性不变.

图 4 可以看出, bPSO 算法中种群的多样性在开始的一段时间有一定的波动并逐步下降, 但在 200 代左右时, 种群多样性不再变化, 使得算法不能有效地跳出局部, 因而容易陷于早熟; 而 IS-PSO 算法的种群多样性总体上也是逐步下降的, 但能保持持续的波动变化, 使算法能跳出局部, 增强了算法全局寻优的能力.

从上述实验比较可以看出: 由于 IS-PSO 引入了免疫调节机制, 因而在演化的过程中, 比较持续地保持了种群的多样性变化, 使得算法能有效地跳出局部最优, 大大提高了函数优化的精度, 特别是对多峰函数的优化.

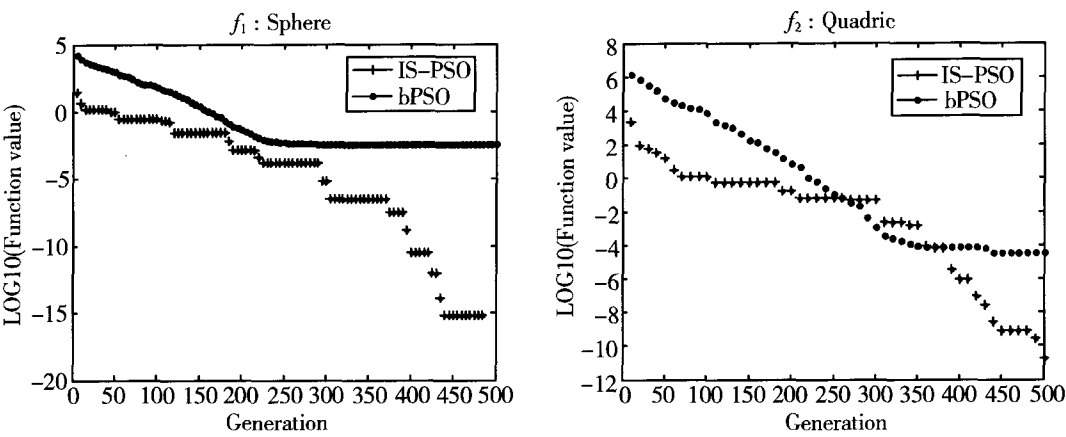


图 2  $f_1$  与  $f_2$  优化仿真结果

Fig. 2 Simulation results of functions  $f_1$  and  $f_2$

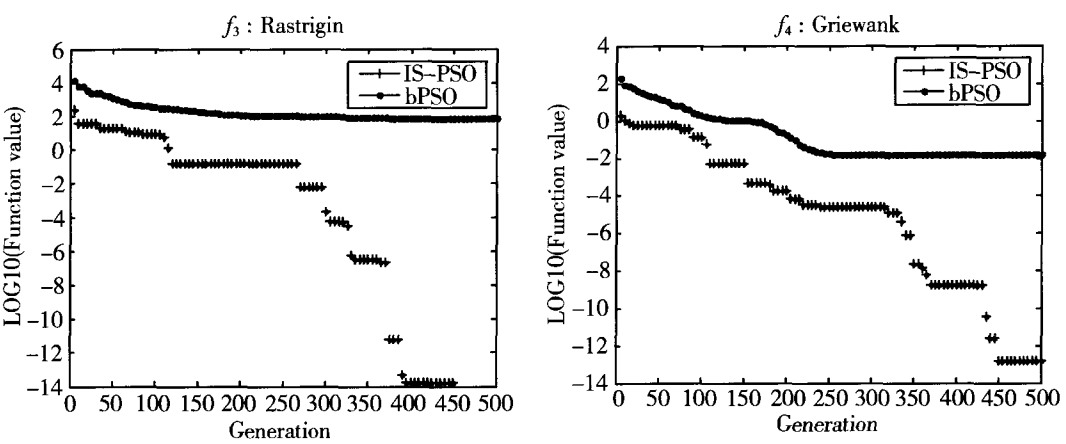


图 3  $f_3$  与  $f_4$  优化仿真结果

Fig. 3 Simulation results of functions  $f_3$  and  $f_4$




图 4 函数  $f_1$  与  $f_3$  种群多样性仿真

Fig. 4 Population diversity simulation results of functions  $f_1$  and  $f_3$

为了测试 IS-PSO 算法的鲁棒性,我们分别对粒子规模为 10、20、30、50 及迭代次数为 300、400、500 参数组合下,对算法进行了多次实验仿真,得到的结果是:粒子规模小和迭代次数少的情况下,算法收敛精度稍差,但比起 bP-PSO 算法总体优化性能要好;在其它情况下,IS-PSO 具有相对稳定的收敛概率和精度.因而,本文提出的 IS-PSO 是稳定的、健壮的.

## 5 结语

由于基本粒子群算法是基于简单随机全局寻优机制,因而在粒子运动到一定阶段后不能较好地保持种群的多样性,容易陷于早熟.本文受生物免疫系统的启发,提出了一种基于免疫选择的粒子群优化算法,其特点主要有:基于实数编码,避免复杂的交叉变异操作,易于实现;对抗原识别、抗体浓度与疫苗的定义进行了新的更有效的尝试,取得了明显的效果;基于亲和力与浓度的抗体促进与抑制机制提高了种群的多样性的概率;免疫记忆、接种疫苗、免疫选择等操作不仅保证优良个体进入下一代,而且增加了种群的多样性,从而提高算法的寻优精度.通过实验仿真,本文提出的 IS-PSO 的寻优性能要明显优于基本的粒子群算法.由于 IS-PSO 算法优化精度高,容易实现,效率较高,因此将该算法应用于高维数据的文档聚类将是我们下一步研究的工作.

## References

- [1] Kennedy J, Eberhart R C. Particle swarm optimisation. Proceedings of IEEE International Conference on Neural Networks, 1995 (4): 1942~1948.
- [2] Tasgetiren M F, Sevkli M, Liang Y C, *et al.* Particle swarm optimization algorithm for permutation flowshop sequencing problem. Proceedings of 4th International workshop on Ant Colony Optimization and Swarm Intelligence, Brussels, Belgium, 2004, 382~389.
- [3] Omkar S N, Dheevatsa M, Narayana N G, *et al.* Vector evaluated particle swarm optimization (VEPSO) for multi-objective design optimization of composite structures. Computers and Structures, 2008, 86: 1~14.
- [4] El-Gallad A I, El-Hawary M E, Sallam A A. Swarming of intelligent particle for solving the nonlinear constrained optimization problem. International Journal of Engineering Intelligent Systems for Electrical Engineering and Communications, 2001, 9(3): 155~163.
- [5] Zhang W, Liu Y T. Adaptive particle swarm optimization for reactive power and voltage control in power systems. Lecture Note in Computer Science, 2005, 449~452.
- [6] Jin Y X, Cheng H Zh, Yan J Y, *et al.* Improved particle swarm optimization method and its application in power transmission network planning. Proceedings of the CSEE, 2005, 25 (4): 46~50, 70.
- [7] Du T J, Chen G J, Liu Zh Ch, *et al.* A network and its simulation for trajectory recognition based on PSO algorithm. Journal of System Simulation, 2004, 16(11): 2517~2519. (杜天军, 陈光禹, 刘占辰. 基于 PSO 算法的弹道辨识网络及仿真. 系统仿真学报, 2004, 16 (11): 2517~2519).
- [8] Marco M, Stefano S, Paola P, *et al.* Improved particle swarm optimization algorithms for electromagnetic optimization. Journal of Intelligent and Fuzzy Systems, 2008, 19(1): 75~84.
- [9] Peram T, Veeramachaneni K, Mohan C K. Fitness-distance-ratio based particle swarm optimization. Proceedings of Swarm Intelligence Symposium, 2003, 174~181.
- [10] Parsopoulos K E, Vrahatis M N. UPSO-A united particle swarm optimization scheme. Lecture Series on Computational Sciences, 2004, 868~873.
- [11] Liang J J, Qin A K, Suganthan P N, *et al.* Comprehensive learning particle swarm optimizer for global optimization of multimodal functions. IEEE Transactions on Evolutionary Computation, 2006, 10: 281~296.
- [12] Ni L F, Zhao K L, Du S D. Ensemble particle swarm algorithm based on mean squared error



- for adaptive equalization. *Journal of Nanjing University (Natural Sciences)*, 2009, 45 (1): 83~188. (倪梁方, 赵康健, 都思丹. 基于均方误差的集粒子云自适应均衡算法. *南京大学学报(自然科学)*, 2009, 45(1): 83~188).
- [13] Al-Kazemi B, Mohan C K. Multi-phase generalization of the particle swarm optimization algorithm. *Proceedings of the 2002 Congress on Evolutionary Computation*. Honolulu, HI, USA. 2002, 1: 489~494.
- [14] Lobjerg M, Rasmussen T K, Krink K. Hybrid particle swarm optimizer with breeding and subpopulations. *Proceedings of the Third Genetic and Evolutionary Computation Conference*, 2001, 1: 469~476.
- [15] Li X D. Adaptively choosing neighborhood using species in particle swarm optimizer for multimodal function optimization. *Proceedings of the Genetic and Evolutionary Computation Conference*, LNCS 31021 Berlin, 2004, 105~116.
- [16] Ursem R K. Diversity-guided evolutionary algorithms. *The 7<sup>th</sup> International Conference on Parallel Problem Solving from Nature*, LNCS 2439, Berlin: Springer, 2002, 462~474.
- [17] Xie X F, Zhang W J, Yang Z L. Adaptive Particle Swarm Optimization on Individual Level. *6<sup>th</sup> International Conference on Signal Processing*. Beijing, China, 2002, 2: 1215~1218.
- [18] Jie J, Zeng J Ch, Han Ch Zh. Self-organized particle swarm optimization based on feedback control of diversity. *Journal of Computer Research and Development*, 2008, 45(3): 467~471. (介 婧, 曾建潮, 韩崇昭. 基于群体多样性反馈控制的自组织微粒群算法. *计算机研究与发展*, 2008, 45(3): 467~471).
- [19] Burnet F M. *The Clonal Selection Theory of Acquired Immunity*. Nashville: Vanderbilt University Press, 1959.
- [20] Chun J S, Jung H K, Hahn S Y. A study on comparison of optimization performances between immune algorithm and other heuristic algorithms. *IEEE Transactions on Magnetics*, 1998, 34 (5): 2972~2975.
- [21] Cui X, Li M, Fang T. Study of population diversity of multiobjective evolutionary algorithm based on immune and entropy principles. *Proceedings of the IEEE Conference on Evolutionary Computation*. 2001, 1316~1321.
- [22] Wang L, Pan J, Jiao L Ch. The immune algorithm. *Acta Electronica Sinica*, 2000, 28(7): 74~78. (王 磊, 潘 进, 焦李成. 免疫算法. *电子学报*, 2000, 28(7): 74~78).
- [23] Zhang J, Liu K Sh, Wang X F. Immune modulated symbiotic evolution in neural network design. *Journal of Computer Research and Development*, 2000, 37(8): 924~930. (张 军, 刘克胜, 王煦法. 一种基于免疫调节和共生进化的神经网络优化设计方法. *计算机研究与发展*, 2000, 37(8): 924~930).
- [24] Gao J. The application of the immune algorithm for power network planning. *Systems Engineering-Theory and Practice*, 2001, 21(5): 119~123. (高 洁. 应用免疫算法进行电网规划研究. *系统工程理论与实践*, 2001, 21 (5): 119~123).
- [25] Shi Y, Eberhart R C. A modified swarm optimizer. *IEEE International Conference of Evolutionary Computation*. Anchorage, Alaska: IEEE Press, May, 1998, 69~73.